

Prueba técnica: Retención y fraude en una aseguradora

Rol: Científico de Datos Freelance · **Duración sugerida:** 2 semanas (≈ 25 horas) · **Herramientas:** Python, Power BI

1. El caso

Andina Seguros vende pólizas de Auto, Salud, Hogar y Vida en Colombia. La gerencia tiene dos dolores de cabeza y un presupuesto limitado:

1. **Se les van los clientes.** Cerca del 19% de las pólizas se cancela y nadie sabe a quién llamar antes de que pase.
2. **Les hacen trampa.** El equipo de investigación (SIU) solo alcanza a revisar una fracción de los reclamos y los escoge casi al azar.

Te contratan para entregar, en 2 semanas: datos limpios, dos modelos predictivos y un tablero que la gerencia pueda usar el lunes por la mañana.

En palabras simples: te dan tres cuadernos desordenados. Debes ordenarlos, aprender de ellos a adivinar quién se va y quién miente, y dibujar un tablero para que el jefe decida a quién llamar y qué reclamos revisar primero.

Reglas del juego

- Escribe **tú mismo** el código. Puedes consultar documentación; si te trabas, ese es el momento de preguntar.
- Cada decisión importante se **justifica por escrito** (una o dos líneas bastan). En una prueba real, el "por qué" vale tanto como el "qué".
- Nada de revisar los archivos limpios de referencia hasta terminar la Fase 1.

Datos entregados

Archivo	Contenido	Llave
clientes_raw.csv	Perfil, ingreso, score, ciudad	cliente_id
polizas_raw.csv	Contratos, prima, estado	poliza_id → cliente_id
reclamos_raw.csv	Siniestros, montos, flag de fraude	reclamo_id → poliza_id

2. Fase 1 · Limpieza y ETL (20 pts)

ELI5: es como ordenar un cuaderno escrito por 50 personas con letras distintas. Antes de sacar conclusiones, todos deben escribir igual.

Tareas

1. **Perfilar** cada tabla: filas, tipos, % de nulos por columna, duplicados, valores únicos de las columnas de texto.

2. **Estandarizar texto:** ciudades, coberturas, estados, canales, género. Crea un diccionario de homologación (por ejemplo, todas las variantes de Bogotá → Bogotá).
3. **Unificar fechas** a un solo formato. Decide qué haces con las inválidas y los nulos.
4. **Tratar numéricas imposibles:** edades, ingresos, primas, scores, horas y montos fuera de rango. Define una regla por columna (¿se anula, se imputa, se elimina la fila?).
5. **Eliminar duplicados exactos** y reportar cuántos eran por tabla.
6. **Validar integridad referencial:** pólizas sin cliente y reclamos sin póliza. Decide qué hacer y documenta cuántas filas afecta.
7. **Reglas de coherencia entre columnas:** fecha_fin posterior a fecha_inicio, siniestro dentro de la vigencia, pagado no mayor al solicitado, etc.
8. **Normalizar la etiqueta de fraude** a 0/1 y la de churn a una variable clara.

Entregables

- 01_et1.ipynb (o .py) reproducible de principio a fin.
- clientes_clean.csv, polizas_clean.csv, reclamos_clean.csv.
- **Tabla de calidad antes/después:** nulos, duplicados y valores inválidos por tabla.
- **Registro de decisiones:** una tabla con *problema* → *regla aplicada* → *filas afectadas* → *por qué*.

Criterios de aceptación

- Cero llaves huérfanas en los archivos limpios (o separadas en un archivo de cuarentena).
- Cada columna categórica tiene valores únicos coherentes.
- Todas las fechas son de tipo fecha real.
- Ejecutar el notebook desde cero reproduce los resultados.

3. Fase 2 · Análisis exploratorio (10 pts)

Responde con gráficos y una frase por hallazgo:

1. ¿Qué cobertura concentra más prima y cuál tiene peor **siniestralidad** (pagado ÷ prima)?
2. ¿Cómo cambia la cancelación según el **incremento de prima**?
3. ¿Los clientes con reclamos rechazados cancelan más?
4. ¿Cuánto cuesta el fraude (monto solicitado en reclamos sospechosos) y en qué coberturas se concentra?
5. ¿Hay diferencias por ciudad, canal de venta o forma de pago?
6. Una pregunta propia que ninguno de los puntos anteriores cubra.

Entregable: 02_edu.ipynb con mínimo 8 gráficos, cada uno con título, ejes legibles y una conclusión de negocio.

4. Fase 3 · Modelo de churn (20 pts)

ELI5: es como una profesora que mira quiénes dejaron de venir a clase el año pasado, aprende qué tenían en común y marca desde ahora a quién va a faltar.

teman en común y marca desde ahora a quien va a llamar.

Tareas

1. Define el **target** (cancelada vs. no) y justifica qué haces con los estados Vencida, Renovada, Activa y Suspendida.
2. Construye la tabla de modelado: una fila por póliza, uniendo cliente, póliza y agregados de reclamos (número de reclamos, rechazados, monto total).
3. **Detecta y excluye el leakage**. Hay columnas que solo existen *después* de cancelar. Explica cuáles y por qué las sacaste.
4. Haz el **split** train/test con estratificación y deja el test sin tocar hasta el final.
5. Entrena un **modelo base** (regresión logística) y un **modelo mejor** (Random Forest, XGBoost o similar). Compáralos.
6. Evalúa con **ROC-AUC, PR-AUC, matriz de confusión, recall y precisión**. Explica por qué la exactitud (accuracy) sola engaña aquí.
7. Calcula el **lift** y la **ganancia acumulada**: si llamas al 10% con mayor riesgo, ¿qué fracción de los que se van capturas?
8. **Explica el modelo**: importancia de variables y, de ser posible, una explicación por cliente.

Caso de negocio (supuestos para el ROI)

- Contactar a un cliente cuesta **\$80,000**.
- La retención funciona en **25%** de los contactados.
- Retener a un cliente conserva su **prima anual**.

Elige el umbral o el % de clientes a contactar que maximice el beneficio neto y muestra la tabla de costo-beneficio.

Entregable: 03_churn.ipynb y churn_scores.csv (póliza, probabilidad, decil de riesgo).

5. Fase 4 · Modelo de fraude (15 pts)

ELI5: el fraude es como encontrar las pocas monedas falsas en un frasco lleno. Como casi todas son buenas, un modelo perezoso que diga "todas son buenas" acertaría el 94%... y sería inútil.

Tareas

1. Analiza el **desbalance** y explica por qué la accuracy no sirve.
2. Crea variables útiles: días entre inicio de póliza y siniestro, ratio monto/suma asegurada, rezago de reporte, horario nocturno, documentos presentados, etc.
3. Entrena un **modelo supervisado** (clasificación con manejo de desbalance: pesos de clase, submuestreo o similar).
4. Prueba un **detector de anomalías no supervisado** (por ejemplo, Isolation Forest) y compáralo contra el supervisado.
5. Evalúa con **PR-AUC, recall y precisión @ top-K**.

Caso de negocio

- El SIU solo puede revisar el **5%** de los reclamos y cada revisión cuesta **\$150,000**.

